

6. Repositorio en GitHub:


- Crear un repositorio en GitHub con el código y los resultados del análisis.
- Crear un tag de liberación con una breve descripción de la versión final del proyecto.


Adicional

- Añadir un archivo README.md en el repositorio de GitHub que explique el propósito del proyecto, las técnicas utilizadas y cómo ejecutar el código.
- Incluir una presentación o informe detallado en formato PDF con todos los hallazgos y conclusiones del análisis.

Nota: Asegúrate de documentar cada paso del proceso, incluyendo la justificación de las decisiones tomadas durante el preprocesamiento, la selección de modelos y la evaluación de los resultados. Esto proporcionará una visión completa y estructurada del trabajo realizado.

<https://github.com/sofiautrera-cpu/-wine-quality-ml-.git>





6.3 Presentación e Informe Final en PDF

Como parte de la entrega profesional del proyecto, se incluye un **informe detallado en formato PDF** que resume todo el proceso de análisis, modelado y evaluación.

Este documento está diseñado para ser presentado a equipos técnicos, stakeholders o como parte de un portafolio profesional.

Contenido del informe PDF

El documento incluye:

- **Resumen ejecutivo** Objetivo del proyecto, dataset utilizado y principales conclusiones.
- **Análisis exploratorio (EDA)** Distribuciones, correlaciones, visualizaciones clave y hallazgos relevantes.
- **Preparación del dataset** Limpieza, creación del target binario, división estratificada y justificación técnica.
- **Modelado** Descripción de los cuatro modelos evaluados, hiperparámetros utilizados y razonamiento detrás de cada enfoque.
- **Evaluación de modelos** Métricas completas (Accuracy, Precision, Recall, F1, AUC), matrices de confusión, curvas ROC y análisis de errores.

- **Ajuste de umbral (Threshold Tuning)** Curvas Precision–Recall, F1 vs threshold y selección del umbral óptimo.
- **Comparación y conclusiones finales** Justificación del modelo ganador (Random Forest), fortalezas, debilidades y recomendaciones.
- **Trabajo futuro** Ideas para mejorar el modelo, interpretabilidad, tuning avanzado y despliegue.

Ubicación del PDF en el repositorio

/docs/

informe_final_wine_quality.pdf

Esto permite:

- Mantener el repositorio ordenado
- Facilitar la lectura del informe sin navegar entre notebooks
- Tener una versión estática y presentable del proyecto

Informe final en PDF con todos los hallazgos, visualizaciones, métricas y conclusiones

Informe Final del Proyecto

Clasificación de la Calidad del Vino Tinto mediante Técnicas de Aprendizaje Automático

Resumen

El presente informe desarrolla un análisis completo orientado a la clasificación de la calidad del vino tinto utilizando técnicas de aprendizaje automático. Se emplea el dataset *Wine Quality – Red Wine* disponible públicamente, el cual contiene variables fisicoquímicas de muestras de vino y una evaluación sensorial de calidad. El objetivo principal es construir modelos capaces de predecir si un vino es de “buena calidad” (≥ 7 puntos) o “no bueno” (< 7 puntos). El estudio incluye: análisis exploratorio, preparación del dataset, entrenamiento de modelos, evaluación comparativa, ajuste de umbral y selección del modelo óptimo. Los resultados muestran que el modelo **Random Forest** ofrece el mejor rendimiento global, alcanzando un **AUC de 0.94** y un **F1 superior al resto de los modelos evaluados**.

1. Introducción

La industria vitivinícola requiere herramientas que permitan evaluar la calidad del vino de manera rápida, objetiva y reproducible. Tradicionalmente, la calidad se determina mediante catas sensoriales realizadas por expertos, un proceso costoso y subjetivo. El uso de modelos de aprendizaje automático permite automatizar esta tarea utilizando variables fisicoquímicas medidas en laboratorio.

El objetivo de este proyecto es desarrollar un sistema de clasificación binaria que determine si un vino es de buena calidad. Para ello se evalúan distintos modelos supervisados y se comparan sus desempeños utilizando métricas adecuadas para datasets desbalanceados.

2. Dataset y Preparación de Datos

El dataset utilizado proviene del repositorio de Jason Brownlee y contiene 1.599 muestras de vino tinto, cada una con 11 variables fisicoquímicas y una variable de calidad sensorial.

2.1 Variables

Las variables incluyen:

- *fixed acidity, volatile acidity, citric acid, residual sugar, chlorides,*

- *free sulfur dioxide, total sulfur dioxide, density, pH, sulphates, alcohol* y la variable objetivo *quality* (0–10).

2.2 Creación del target binario

Se definió:

- **1 = vino bueno** ($\text{quality} \geq 7$)
- **0 = no bueno** ($\text{quality} < 7$)

El dataset presenta un **desbalance significativo**, con aproximadamente 14% de vinos buenos.

2.3 División en entrenamiento y prueba

Se utilizó un *train-test split* estratificado (80/20) para mantener la proporción de clases en ambos subconjuntos.

3. Análisis Exploratorio (EDA)

El análisis exploratorio permitió identificar:

3.1 Distribución del target

Existe un desbalance marcado: la mayoría de los vinos se clasifican como “no buenos”. Esto implica que métricas como Accuracy no son adecuadas para evaluar el rendimiento del modelo.

3.2 Correlaciones

Las variables con mayor correlación con la calidad fueron:

- **alcohol** (positiva)
- **volatile acidity** (negativa)
- **sulphates** (positiva)

La matriz de correlación mostró relaciones moderadas entre variables químicas, lo que sugiere la necesidad de modelos capaces de capturar interacciones no lineales.

4. Modelado y Evaluación

Se entrenaron cuatro modelos utilizando *pipelines* con **StandardScaler**:

- **KNN (k=11)**
- **Decision Tree (max_depth=5)**

- **Random Forest (200 árboles)**
- **Logistic Regression**

4.1 Métricas utilizadas

Debido al desbalance, se priorizaron:

- **Precision**
- **Recall**
- **F1-Score**
- **AUC (ROC)**

4.2 Resultados generales

El modelo **Random Forest** obtuvo el mejor rendimiento global, destacando en F1 y AUC. KNN fue el modelo con peor desempeño, mientras que Logistic Regression mostró buen AUC pero bajo Recall.

4.3 Matrices de confusión

Las matrices revelaron que Random Forest presenta la mejor relación entre verdaderos positivos y falsos negativos, lo cual es crucial para no perder vinos de buena calidad.

4.4 Curva ROC

El modelo Random Forest alcanzó un **AUC $\approx$ 0.94**, indicando una excelente capacidad discriminativa.

5. Ajuste de Umbral (Threshold Tuning)

El umbral por defecto (0.5) no es óptimo en datasets desbalanceados. Se generaron curvas Precision–Recall y F1 vs threshold para seleccionar el umbral que maximiza F1.

El threshold óptimo permitió:

- Reducir falsos negativos
- Aumentar Recall
- Mejorar el equilibrio entre Precision y Recall

Este ajuste es fundamental para aplicaciones donde es preferible detectar la mayor cantidad de vinos buenos.

6. Comparación de Modelos

6.1 Modelo ganador

El modelo **Random Forest (200 árboles)** fue el mejor evaluado debido a:

- Mayor F1
- Mayor AUC
- Mejor equilibrio entre Precision y Recall
- Robustez ante el desbalance
- Capacidad para capturar relaciones no lineales

6.2 Fortalezas y debilidades

Modelo	Fortalezas	Debilidades
Random Forest	Alto rendimiento, robusto, excelente AUC	Menos interpretable
Decision Tree	Fácil de interpretar, buen Recall	Inestable, menor F1
Logistic Regression	Simple, interpretable, buen AUC	Baja capacidad no lineal, bajo Recall
KNN	Simple	Peor rendimiento, sensible al ruido

7. Conclusiones

El proyecto demuestra que es posible predecir la calidad del vino tinto utilizando variables fisicoquímicas y modelos de aprendizaje automático. El modelo Random Forest se posiciona como la mejor alternativa, ofreciendo un rendimiento sólido y estable.

El ajuste de umbral permite adaptar el modelo a distintos objetivos de negocio, ya sea maximizar Recall (no perder vinos buenos) o maximizar Precision (evitar falsos positivos).

Este estudio constituye una base sólida para futuras mejoras, como tuning avanzado, interpretabilidad mediante SHAP o despliegue del modelo en un entorno productivo.

8. Trabajo Futuro

Se proponen las siguientes líneas de mejora:

- Optimización de hiperparámetros mediante *GridSearchCV* o *Bayesian Optimization*
- Aplicación de técnicas de interpretabilidad (SHAP, LIME)
- Manejo avanzado del desbalance (SMOTE, class weights)
- Implementación de un pipeline completo para despliegue
- Extensión del análisis a vinos blancos o datasets combinados

9. Referencias

- Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Modeling wine preferences by data mining from physicochemical properties.*
- UCI Machine Learning Repository – Wine Quality Dataset.
- Brownlee, J. (2020). *Machine Learning Mastery Datasets.*